



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΣΥΣΤΗΜΑΤΩΝ ΜΕΤΑΔΟΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ ΥΛΙΚΩΝ

**«Αυτοματοποιημένη παραγωγή συνθετικών συνόλων δεδομένων
κατάτμησης στιγμιοτύπων σε ογκολογικές ιατρικές εικόνες από
δημόσια διαθέσιμα σύνολα δεδομένων»**

Εξαμηνιαία Εργασία

στο μάθημα «Τεχνολογίες Κινητής και Ηλεκτρονικής Υγείας»

των φοιτητών

Ζακυνθινού Ιάσονα-Δανιήλ, Α.Μ.: 03123408

Ντόντου Στέργιου, Α.Μ.: 03123406

Πάλλη Γεώργιου, Α.Μ.: 03122144

Τουρκοχωρίτη Ευάγγελου, Α.Μ.: 03122273

Διδάσκοντες: Δ. Κουτσούρης, Κ. Νικήτα, Γ. Ματσόπουλος

Υπεύθυνος Άσκησης: Παναγιώτης Τσανάκας, Αθανάσιος Δελής

Αθήνα, Ιούνιος 2020

Η σελίδα αυτή είναι σκόπιμα λευκή.

Περίληψη

Η αυτόματη ανάλυση ιατρικών εικόνων αποτελεί σημαντικό εργαλείο στη σύγχρονη ιατρική απεικόνιση και, ειδικότερα, στην ογκολογική διάγνωση. Η εκπαίδευση αξιόπιστων μοντέλων τεχνητής νοημοσύνης απαιτεί μεγάλα σύνολα δεδομένων με ακριβείς επισημειώσεις, η δημιουργία των οποίων είναι ιδιαίτερα χρονοβόρα και κοστοβόρα, καθώς απαιτεί τη συμβολή εξειδικευμένων ιατρών.

Σκοπός της παρούσας εργασίας ήταν η ανάπτυξη ενός αυτοματοποιημένου pipeline για την παραγωγή συνθετικών масκών instance segmentation και polygon-based annotations σε ογκολογικές ιατρικές εικόνες. Η προσέγγιση αξιοποίησε τρία δημόσια ανοικτά σύνολα δεδομένων: το BraTS 2020 για όγκους εγκεφάλου [2]-[4], το BUSI dataset για καρκίνο μαστού (υπέρηχοι) [5] και το Brain Tumor dataset.

Η μεθοδολογία βασίστηκε στην εφαρμογή και αυστηρή σύγκριση 12 διαφορετικών μεθόδων εξαγωγής масκών που εκτείνονται σε τρεις κατηγορίες: κλασικές τεχνικές υπολογιστικής όρασης (όπως Otsu [6], Watershed [8], Random Walker [9] και Chan-Vese [10]), μοντέλα βάσης (όπως το SAM [1]) και εκπαιδύσιμα δίκτυα κατάτμησης (U-Net [12] και Guided U-Net [13]). Οι παραγόμενες μάσκες μετατράπηκαν αυτόματα σε polygon annotations, κατάλληλα για την εκπαίδευση δικτύων ανιχνεύσιμου αντικειμένων.

Η ποιότητα των συνθετικών масκών αξιολογήθηκε εκτενώς με μετρικές όπως το Intersection over Union (IoU) έναντι масκών αναφοράς (ground truth). Στη συνέχεια, τα δεδομένα των δύο κορυφαίων μεθόδων ανά σύνολο χρησιμοποιήθηκαν για την εκπαίδευση και συγκριτική αξιολόγηση μοντέλων YOLOv11 και YOLOv26 [14], [15].

Τα ευρήματα καταδεικνύουν σαφείς διαφορές απόδοσης μεταξύ κλασικών, foundation και learned μεθόδων, αναδεικνύοντας παράλληλα τις προκλήσεις της μεταφοράς γνώσης (cross-domain transfer) σε σύνολα χωρίς αρχικές επισημειώσεις. Συμπερασματικά, η προτεινόμενη ροή εργασίας προσφέρει μια αποδοτική, αυτοματοποιημένη εναλλακτική για την κλιμάκωση της παραγωγής συνθετικών ογκολογικών δεδομένων, μειώνοντας δραστηκά την εξάρτηση από τις χειροκίνητες ιατρικές επισημειώσεις.

Λέξεις Κλειδιά

Ιατρική απεικόνιση, Ογκολογία, Συνθετικά Σύνολα Δεδομένων, Instance segmentation, YOLO segmentation

Η σελίδα αυτή είναι σκόπιμα λευκή.

Πίνακας Περιεχομένων

1 Εισαγωγή

- 1.1 Θέμα και αντικείμενο
- 1.2 Ανάλυση Ενδιαφέροντος του Θέματος
 - 1.2.1 Επιστημονική Πλευρά
 - 1.2.2 Πρακτική Πλευρά
- 1.3 Ανάλυση

2 Υλικό και Μέθοδοι

- 2.1 Σύνολα Δεδομένων
- 2.2 Δείκτες Αξιολόγησης
- 2.3 Αλυσίδα Επεξεργασίας και Μέθοδοι Κατάτμησης

3 Αποτελέσματα

- 3.1 Αξιολόγηση Παραγωγής Συνθετικών Μασκών (Φάση 1)
- 3.2 Εκπαίδευση Νευρωνικών Δικτύων Κατάτμησης (Φάση 1D)
- 3.3 Αξιολόγηση Μοντέλων Ανίχνευσης YOLO (Φάση 2)

4 Συμπεράσματα - Επίλογος

- 4.1 Σύνοψη και Ερμηνεία Ευρημάτων
 - 4.1.1 Φάση 1
 - 4.1.2 Φάση 1D
 - 4.1.3 Φάση 2
- 4.2 Θεωρητική και Πρακτική Σημασία
- 4.3 Περιορισμοί και Μελλοντική Έρευνα

5 Βιβλιογραφία

Η σελίδα αυτή είναι σκόπιμα λευκή.

1

Εισαγωγή

1.1 Θέμα και αντικείμενο

Η ανάλυση ιατρικών εικόνων αποτελεί ένα από τα πιο δυναμικά πεδία της σύγχρονης βιοϊατρικής μηχανικής, προσφέροντας κρίσιμα εργαλεία για τη διάγνωση και παρακολούθηση ογκολογικών παθήσεων. Η ενσωμάτωση τεχνικών Τεχνητής Νοημοσύνης και, ειδικότερα, της Βαθιάς Μάθησης έχει βελτιώσει δραματικά την ακρίβεια της κατάτμησης στιγμιοτύπων (instance segmentation) σε απεικονίσεις μαγνητικής τομογραφίας (MRI) και υπερήχων. Ωστόσο, η εκπαίδευση ισχυρών και αξιόπιστων μοντέλων απαιτεί εκτεταμένα σύνολα δεδομένων με λεπτομερείς επισημειώσεις σε επίπεδο εικονοστοιχείου (pixel-level masks) ή πολυγώνου (polygon labels), μια διαδικασία που είναι εξαιρετικά χρονοβόρα, κοστοβόρα και απαιτεί τη συμβολή εξειδικευμένων ιατρών.

Αντικείμενο της παρούσας εργασίας είναι η αυτοματοποιημένη παραγωγή συνθετικών συνόλων δεδομένων κατάτμησης στιγμιοτύπων σε ογκολογικές ιατρικές εικόνες, αξιοποιώντας δημόσια διαθέσιμα σύνολα δεδομένων. Ειδικότερα, διερευνάται η αλυσίδα επεξεργασίας (pipeline) που εκκινεί από απλά πλαίσια οριοθέτησης (bounding boxes) και καταλήγει σε ακριβείς μάσκες, οι οποίες εν συνεχεία μετατρέπονται σε πολύγωνα μέσω αλγοριθμικών υποδομών.

1.2 Ανάλυση Ενδιαφέροντος του Θέματος

1.2.1 Επιστημονική Πλευρά

Από επιστημονικής πλευράς, το ενδιαφέρον της εργασίας έγκειται στην εκτενή, δομημένη σύγκριση τριών θεμελιωδών προσεγγίσεων για τη δημιουργία масκών: των κλασικών, μη-εκπαιδευσιμων μεθόδων υπολογιστικής όρασης (π.χ. Otsu [6], Watershed [8], Connected Components), των προ-εκπαιδευμένων Μοντέλων Βάσης (Foundation Models, όπως το SAM [1]) και των πλήρως ή μερικώς επιβλεπόμενων νευρωνικών δικτύων (όπως τα U-Net [12] και Guided U-Net [13]). Παράλληλα, η μελέτη ανταποκρίνεται άμεσα σε ανοιχτά ζητήματα της επιστημονικής κοινότητας, προσφέροντας εμπειρική επιβεβαίωση για το αν και κατά πόσο η χρήση μεθόδων αιχμής υπερτερεί των αμιγώς παραδοσιακών τεχνικών.

1.2.2 Πρακτική Πλευρά

Από πρακτικής πλευράς, τα αποτελέσματα της παρούσας μελέτης απευθύνονται άμεσα στην ερευνητική κοινότητα της ιατρικής πληροφορικής και στους μηχανικούς μηχανικής μάθησης. Ένα αξιόπιστο και πλήρως αυτοματοποιημένο pipeline παραγωγής δεδομένων επιτρέπει την ταχεία εκπαίδευση γρήγορων και ελαφρών μοντέλων εντοπισμού αντικειμένων, όπως τα YOLOv11 και YOLOv26 [14], [15]. Αυτό μειώνει δραστικά το κόστος και τον κύκλο ανάπτυξης κλινικών διαγνωστικών εργαλείων.

1.3 Ανάλυση

Η ανάλυση του προβλήματος πραγματοποιείται μέσα από ένα αυστηρό πειραματικό πλαίσιο δύο φάσεων πάνω σε τρία διαφορετικά ογκολογικά σύνολα: το BUSI (υπέρηχοι μαστού) [5], το BraTS 2020 (MRI εγκεφάλου) [2]-[4] και το Brain Tumor dataset (MRI χωρίς αρχικές επισημειώσεις). Στην πρώτη φάση εφαρμόζονται 12 συνολικά μέθοδοι παραγωγής μασκών και αξιολογούνται βάσει μετρικών όπως το Intersection over Union (IoU). Στη δεύτερη φάση, οι δύο κορυφαίες μέθοδοι ανά σύνολο δεδομένων χρησιμοποιούνται για την εκπαίδευση μοντέλων YOLO, προκειμένου να αποδειχθεί έμπρακτα η εγκυρότητα των συνθετικών δεδομένων.

Βάσει του παραπάνω θεωρητικού και πειραματικού πλαισίου, η εργασία καλείται να απαντήσει στα ακόλουθα κεντρικά ερευνητικά ερωτήματα:

1. Πώς συγκρίνονται –από πλευράς ακρίβειας (IoU) και υπολογιστικού κόστους– οι παραδοσιακές μέθοδοι υπολογιστικής όρασης με τα σύγχρονα Foundation Models και τα επιβλεπόμενα Δίκτυα Κατάτμησης (Learned Networks) στην παραγωγή συνθετικών μασκών;
2. Σε ποιο βαθμό είναι εφικτή και αξιόπιστη η μεταφορά γνώσης (cross-domain transfer) για τη δημιουργία μασκών σε σύνολα δεδομένων όπου απουσιάζουν πλήρως οι επισημειώσεις ελέγχου, όπως στην περίπτωση του Brain Tumor dataset;
3. Ποια είναι η επίπτωση της επιλογής της μεθόδου παραγωγής συνθετικών δεδομένων στην τελική προβλεπτική ικανότητα (mAP) σύγχρονων αρχιτεκτονικών ανίχνευσης, όπως το YOLOv11 και το YOLOv26;

2

Υλικό και Μέθοδοι

Στην ενότητα αυτή παρουσιάζεται το θεωρητικό και πειραματικό υπόβαθρο της μελέτης. Γίνεται αναλυτική περιγραφή των τριών ογκολογικών συνόλων δεδομένων που χρησιμοποιήθηκαν, καθώς και της διαδικασίας προκαταρκτικής επεξεργασίας τους. Επιπλέον, θεμελιώνονται μαθηματικά οι αλγόριθμοι επεξεργασίας και παραγωγής συνθετικών масκών, επεξηγείται η αρχιτεκτονική της συνολικής αλυσίδας επεξεργασίας (pipeline) και ορίζονται οι μεθοδολογίες αξιολόγησης της ποιότητας των παραγόμενων δεδομένων μέσω δεικτών ακρίβειας και εκπαίδευσης προηγμένων μοντέλων κατάτμησης.

2.1 Σύνολα Δεδομένων

Η πειραματική διαδικασία βασίζεται σε τρία δημόσια διαθέσιμα ογκολογικά σύνολα δεδομένων διαφορετικών απεικονιστικών μεθόδων, επιτρέποντας την αξιολόγηση της γενικευσιμότητας του pipeline:

1. **BUSI (Breast Ultrasound Dataset):** Περιλαμβάνει εικόνες υπερηχογραφήματος μαστού με αλλοιώσεις (φυσιολογικές, καλοήθειες, κακοήθειες) και τις αντίστοιχες μάσκες αναφοράς [5].
2. **BraTS 2020 (Brain Tumor Segmentation):** Περιλαμβάνει πολυπαραμετρικές μαγνητικές τομογραφίες (MRI) εγκεφάλου για γλοιώματα, με τρισδιάστατες μάσκες ειδικών. Στην παρούσα εργασία απομονώνονται δισδιάστατες αξονικές τομές με κύρια χρήση της ακολουθίας FLAIR [2]-[4].
3. **Brain Tumor (Ultralytics):** Περιλαμβάνει εικόνες MRI εγκεφάλου, οι οποίες όμως διαθέτουν αποκλειστικά οριοθετημένα πλαίσια χωρίς μάσκες αναφοράς [22].

Για τα σύνολα BUSI και BraTS 2020, τα bounding boxes εξάγονται αυτόματα από τις υπάρχουσες μάσκες των ειδικών, προκειμένου να προσομοιωθεί η διαδικασία εισόδου του pipeline.

2.2 Δείκτες Αξιολόγησης

Η ποσοτική αξιολόγηση των παραγόμενων συνθετικών масκών (A) ως προς τις μάσκες αναφοράς (B) πραγματοποιείται με τη χρήση της μετρικής Intersection over Union (IoU), η οποία ορίζεται από την ακόλουθη μαθηματική σχέση:

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

όπου η τιμή IoU κυμαίνεται στο διάστημα $[0, 1]$, με την τιμή 1 να υποδηλώνει απόλυτη ταύτιση της συνθετικής μάσκας με την επισημείωση του ειδικού. Συμπληρωματικά, υπολογίζεται και ο δείκτης Dice coefficient καθώς και η μέτρηση του συνολικού χρόνου εκτέλεσης σε δευτερόλεπτα (runtime).

Η αξιολόγηση των σύγχρονων μοντέλων ανεντοπισμού και κατάτμησης της Φάσης 2 βασίζεται στον σύνθετο δείκτη mAP (Mean Average Precision). Ο δείκτης αυτός συγκεράζει δύο θεμελιώδεις μετρικές: την Ακρίβεια (Precision - P) και την Ανάκληση (Recall - R).

- **Ακρίβεια (P):** Το ποσοστό των ορθών προβλέψεων ως προς το σύνολο των προβλέψεων του μοντέλου.

$$P = \frac{TP}{TP + FP}$$

- **Ανάκληση (R):** Το ποσοστό των πραγματικών ογκολογικών βλαβών που το μοντέλο κατάφερε να εντοπίσει.

$$R = \frac{TP}{TP + FN}$$

Για να χαρακτηριστεί μια πρόβλεψη ως Ορθά Θετική (TP), πρέπει η επικάλυψη (IoU) με τη μάσκα αναφοράς να υπερβαίνει ένα προκαθορισμένο κατώφλι (t). Η Μέση Μέση Ακρίβεια (mAP) υπολογίζεται πρακτικά ως το μέσο εμβαδόν κάτω από την καμπύλη Precision-Recall για όλες τις κλάσεις (C):

$$mAP = \frac{1}{C} \sum_{i=1}^C \int_0^1 P_i(R) dR$$

Στην παρούσα μελέτη, η αξιολόγηση πραγματοποιείται σε δύο επίπεδα αυστηρότητας:

1. **mAP50:** Αξιολογεί την ικανότητα βασικού εντοπισμού. Μια πρόβλεψη θεωρείται επιτυχής εάν $IoU \geq 0.50$
2. **mAP50-95:** Αποτελεί μια αυστηρότερη μετρική ελέγχου ποιότητας, υπολογίζοντας τον μέσο όρο του mAP για 10 διαφορετικά κατώφλια IoU, από 0.50 έως 0.95 με βήμα 0.05. Η μετρική αυτή αναδεικνύει το πόσο τέλεια "αγκαλιάζει" το πολύγωνο την πραγματική βλάβη.

Τέλος, λόγω της διττής φύσης των μοντέλων Instance Segmentation, οι δείκτες διαχωρίζονται σε B_mAP (Box mAP), που αξιολογεί αποκλειστικά την τοποθέτηση των οριακών πλαισίων (bounding boxes), και σε M_mAP (Mask mAP), που αξιολογεί τη λεπτομερή σχεδίαση των πολυγώνων σε επίπεδο εικονοστοιχείου (pixel-level accuracy).

2.3 Αλυσίδα Επεξεργασίας και Μέθοδοι Κατάτμησης

Το προτεινόμενο pipeline υλοποιεί μια ενιαία υποδομή επεξεργασίας, η οποία δέχεται ως είσοδο την εικόνα και τα pixel coordinates των οριακών πλαισίων. Κάθε αλγόριθμος παραγωγής масκών υποχρεούται να ακολουθεί μια αυστηρή κοινή δομή κλήσης (*generate_masks*), διασφαλίζοντας την αντικειμενικότητα της σύγκρισης. Συνολικά, στην 1η Φάση, εξετάζονται 12 μέθοδοι, οι οποίες ταξινομούνται σε τρεις κατηγορίες:

- **Κλασικές Μέθοδοι (1–9):** Μη-εκπαιδευσιμοι αλγόριθμοι υπολογιστικής όρασης (Otsu [6], Multi-Otsu [7], Adaptive Thresholding, Pure Watershed [8], Otsu+Watershed, Connected Components, Random Walker [9], Chan-Vese [10], Morphological GAC [11]).
- **Μοντέλα Βάσης (10):** Προ-εκπαιδευμένα μοντέλα zero-shot ικανότητας, όπως το Segment Anything Model (SAM) της Meta [1], καθοδηγούμενο από το οριακό πλαίσιο.
- **Εκπαιδευσιμα Δίκτυα (11–12):** Προσεγγίσεις βαθιάς μάθησης που περιλαμβάνουν ένα τυπικό Vanilla U-Net (πλήρης επίβλεψη, oracle baseline) [12] και ένα Guided U-Net [13], το οποίο εκπαιδεύεται λαμβάνοντας ως επιπλέον είσοδο την κωδικοποίηση του πλαισίου (box-supervised).

Μετά την παραγωγή των δυαδικών масκών, η μετατροπή τους στην τελική μορφή πολυγώνων πραγματοποιείται κεντρικά μέσω της συνάρτησης *cv2.findContours* της βιβλιοθήκης OpenCV.

Επιπρόσθετα, παρεμβάλλεται η ενδιάμεση Φάση 1D, κατά την οποία τα δίκτυα Vanilla U-Net και Guided U-Net εκπαιδεύονται από το μηδέν στα σύνολα δεδομένων, με σκοπό να λειτουργήσουν ως το ανώτατο θεωρητικό όριο για τη συγκριτική αξιολόγηση των υπολοίπων μεθόδων.

Στη 2η Φάση του πειράματος, τα συνθετικά δεδομένα των δύο κορυφαίων μεθόδων (βάσει IoU) χρησιμοποιούνται για την εκπαίδευση των μοντέλων instance segmentation YOLOv11 [14] και YOLOv26 [15], ώστε να αξιολογηθεί η πρακτική χρησιμότητα των αυτοματοποιημένων επισημειώσεων στην εκπαίδευση real-time ανιχνευτών.


#	Μέθοδος (Κατηγορία)	BUSI	BraTS 2020	Brain Tumor
1	Otsu thresholding (Κλασική)	E040	E052	E064
2	Multi-Otsu thresholding (Κλασική)	E041	E053	E065
3	Adaptive thresholding (Κλασική)	E042	E054	E066
4	Pure Watershed (Κλασική)	E043	E055	E067
5	Otsu + Watershed (Κλασική - Baseline)	E044	E056	E068
6	ConnectedComponents (Κλασική)	E045	E057	E069
7	Random Walker (Κλασική)	E046	E058	E070
8	Chan-Vese (Κλασική)	E047	E059	E071
9	Morphological GAC (Κλασική)	E048	E060	E072
10	SAM (bbox-prompted) (Foundation)	E049	E061	E073
11	U-Net (vanilla) (Learned)	E050	E062	E074
12	Guided U-Net (Learned)	E051	E063	E075

Πίνακας 1: Κατανομή των 12 μεθόδων παραγωγής масκών ανά σύνολο δεδομένων και οι αντίστοιχοι κωδικοί πειραμάτων της 1ης Φάσης.


3

Αποτελέσματα

3.1 Αξιολόγηση Παραγωγής Συνθετικών Μασκών (Φάση 1)



Διάγραμμα 1: Η ακρίβεια (IoU) των 12 μοντέλων, για τα σύνολα δεδομένων BUSI και BraTS.




Διάγραμμα 2: Η ακρίβεια (αριστερά) σε σύγκριση με τον χρόνο ολοκλήρωσης (δεξιά) των 12 μοντέλων, για το BUSI σύνολο δεδομένων, για την διερεύνηση της αποδοτικότητας τους.

Από τα αποτελέσματα της 1ης φάσης του πειράματος, μπορούμε να αντλήσουμε πληροφορίες σχετικά με την ταχύτητα και την ακρίβεια των 12 μεθόδων που εφαρμόσαμε και θέλουμε να συγκρίνουμε.

Από τις κλασικές μεθόδους που χρησιμοποιήθηκαν, ικανότερη αναδείχθηκε η *Morph GAC* [11] (0.75 accuracy), ενώ το *SAM* [1] και τα εκπαιδευσιμα δίκτυα είχαν σημαντικά καλύτερα αποτελέσματα, με το *U-net* [12] να ξεπερνά το 0.9 accuracy. Έτσι, αποδεικνύεται έμπρακτα η ανωτερότητα των μοντέλων αυτών έναντι των απλών αλγορίθμων υπολογιστική όρασης.


Ταυτόχρονα, εξετάζοντας το Διάγραμμα 2, μπορεί κανείς να αξιολογήσει και την αποδοτικότητα των μοντέλων, συνυπολογίζοντας το συνολικό runtime που απαιτούν για να παράξουν τα αποτελέσματά τους. Και από αυτήν την προοπτική, τα εκπαιδευσιμα δίκτυα έχουν ικανοποιητική επίδοση, ενώ αυτή τη φορά αναδεικνύεται το πλεονέκτημα των αλγορίθμων υπολογιστικής όρασης, οι οποίοι χρειάζονται αναλογικά λιγότερο χρόνο για την παραγωγή των αποτελεσμάτων τους. Αξιοσημείωτοι κατά αυτή την έννοια είναι οι *Adaptive Thresholding* και *Watershed*.




Διάγραμμα 3: Χρόνος εκτέλεσης των 12 μεθόδων, σε κάθε σύνολο δεδομένων

Η ανάλυση της υπολογιστικής αποδοτικότητας επεκτάθηκε και στο σύνολο Brain Tumor. Παρά την απουσία μασκών αναφοράς που καθιστά αδύνατη την άμεση μέτρηση του IoU, η καταγραφή των χρόνων εκτέλεσης ανέδειξε ότι τα δίκτυα U-Net και Guided U-Net ολοκλήρωσαν την παραγωγή масκών σε μόλις ~18.5 και ~20.8 δευτερόλεπτα αντίστοιχα (με χρήση GPU). Αντίθετα, αλγόριθμοι όπως το SAM (GPU) και το κλασικό Watershed (CPU) απαίτησαν 586.9 και 256.7 δευτερόλεπτα, γεγονός που αναδεικνύει το U-Net ως την πλέον κλιμακώσιμη λύση για τεράστια σύνολα δεδομένων.

3.2 Εκπαίδευση Νευρωνικών Δικτύων Κατάτμησης (Φάση 1D)



Διάγραμμα 4: Πορεία εκπαίδευσης των U-net και Guided U-net για το BUSI σύνολο δεδομένων



Διάγραμμα 5: Πορεία εκπαίδευσης των U-net και Guided U-net για το BraTS σύνολο δεδομένων

Η εξέλιξη της εκπαίδευσης για τα μοντέλα *Vanilla U-Net* [12] και *Guided U-Net* [13] καταδεικνύει ομαλή σύγκλιση και για τα δύο σύνολα δεδομένων (Διαγράμματα 4 και 5). Στο σύνολο BUSI, η απώλεια εκπαίδευσης (train loss) μειώνεται σταθερά σε όλη τη διάρκεια των 20 εποχών. Το validation loss ακολουθεί πτωτική πορεία έως την εποχή 13-17, όπου και σταθεροποιείται κοντά στο 0.24-0.25, υποδεικνύοντας ότι τα μοντέλα εκπαιδεύτηκαν αποτελεσματικά χωρίς έντονα φαινόμενα υπερεκπαίδευσης (overfitting). Το τελικό Validation IoU κορυφώθηκε στο 0.872 για το *Vanilla U-Net* (εποχή 19) και στο 0.872 για το *Guided U-Net* (εποχή 17).


Αντίστοιχη συμπεριφορά παρατηρείται και στο σύνολο BraTS 2020. Το validation loss ελαχιστοποιήθηκε γύρω στην 11η έως 13η εποχή, ενώ μετά την εποχή 17 παρατηρείται μια ελαφριά άνοδος (από 0.285 σε 0.315), χαρακτηριστική της έναρξης ήπιου overfitting, καθώς το μοντέλο αρχίζει να αποστηθίζει τα χαρακτηριστικά εκπαίδευσης. Οι μέγιστες επιδόσεις ακρίβειας που καταγράφηκαν ήταν 0.817 IoU για το *Vanilla U-Net* (εποχή 15) και 0.820 IoU για το *Guided U-Net* (εποχή 15). Αυτές οι τιμές αποδεικνύουν τη δυναμική και των δύο αρχιτεκτονικών να λειτουργήσουν ως ισχυρά "oracle baselines" για τη σύγκριση με τις κλασικές μεθόδους.

3.3 Αξιολόγηση Μοντέλων Ανίχνευσης YOLO (Φάση 2)

Dataset	Πηγή Μασκώ ν	Αρχιτε κτονική	Epochs	Box_m AP50	Box_m AP50_9 5	Mask_mAP50	Mask_mAP50 _95	Χρόνος (Λεπτά)
BUSI	Guided U-Net	YOLO11 x-seg	50	0.883	0.652	0.877	0.661	14.3
BUSI	U-Net	YOLO11 x-seg	50	0.875	0.656	0.871	0.671	12.1
BUSI	Guided U-Net	YOLO26 x-seg	50	0.889	0.650	0.888	0.661	18.6
BUSI	U-Net	YOLO26 x-seg	50	0.885	0.646	0.883	0.677	15.0
BraTS	Guided U-Net	YOLO11 x-seg	50	0.621	0.419	0.617	0.386	436.4
BraTS	U-Net	YOLO11 x-seg	39	0.598	0.415	0.601	0.388	608.2
BraTS	Guided U-Net	YOLO26 x-seg	50	0.586	0.397	0.586	0.372	352.0

BraTS	U-Net	YOLO26 x-seg	41	0.589	0.404	0.590	0.382	563.0
Brain Tumor	Guided U-Net	YOLO11 x-seg	10	0.435	0.342	0.434	0.274	27.9
Brain Tumor	U-Net	YOLO11 x-seg	10	0.757	0.642	0.757	0.581	27.7
Brain Tumor	Guided U-Net	YOLO26 x-seg	6	0.432	0.325	0.428	0.264	21.3
Brain Tumor	U-Net	YOLO26 x-seg	13	0.756	0.613	0.756	0.556	44.0

Πίνακας 2: Μετρικές μέσης ακρίβειας για τα μοντέλα YOLO, για κάθε dataset και για τις δύο καλύτερες πηγές μασκών (U-net και Guided U-net).



Διάγραμμα 6: Σύγκριση των δύο μοντέλων YOLO με βάση την μετρική Mask_mAP50 για τα σύνολα δεδομένων.

Στη δεύτερη φάση της πειραματικής διαδικασίας, τα συνθετικά δεδομένα (polygon labels) που παρήχθησαν από τις δύο κορυφαίες μεθόδους της Φάσης 1 (Vanilla U-Net και Guided U-Net) χρησιμοποιήθηκαν για την εκπαίδευση σύγχρονων μοντέλων αντεντοπισμού στιγμιотύπων, και συγκεκριμένα των αρχιτεκτονικών YOLOv11x-seg [15] και

YOLOv26x-seg [14]. Στόχος ήταν η αξιολόγηση της πρακτικής χρησιμότητας των αυτοματοποιημένων μασκών στην εκπαίδευση πραγματικών διαγνωστικών εργαλείων.

Στον Πίνακα 2 παρουσιάζονται αναλυτικά οι μετρικές μέσης ακρίβειας (mAP) για τα οριακά πλαίσια (B_mAP) και τις μάσκες (M_mAP), καθώς και ο συνολικός χρόνος εκπαίδευσης. Η ανάλυση των αποτελεσμάτων αναδεικνύει τις εξής βασικές παρατηρήσεις:

- Η εκπαίδευση στο **σύνολο BUSI** απέδωσε εξαιρετικά υψηλές τιμές ακρίβειας, επιβεβαιώνοντας την υψηλή ποιότητα των συνθετικών μασκών. Τα μοντέλα επέδειξαν αξιοσημείωτη σταθερότητα, επιτυγχάνοντας τιμές M_mAP50 (Mask mAP στο 50% IoU threshold) που κυμάνθηκαν από 0.859 έως 0.887. Παρατηρείται ότι οι μάσκες που παρήχθησαν από το Guided U-Net οδήγησαν σε οριακά καλύτερα αποτελέσματα κατά την εκπαίδευση των μοντέλων YOLO σε σχέση με το Vanilla U-Net (π.χ., μέγιστο M_mAP50 0.887 έναντι 0.883).
- Όπως ήταν θεωρητικά αναμενόμενο, η πολυπλοκότητα των πολυπαραμετρικών απεικονίσεων MRI οδήγησε σε χαμηλότερες συνολικές αποδόσεις σε σύγκριση με τους υπερήχους. Στο **σύνολο BraTS**, η υψηλότερη τιμή M_mAP50 καταγράφηκε στο 0.617 (Guided U-Net με YOLOv11x-seg). Αξίζει να σημειωθεί πως ο υπολογιστικός χρόνος για αυτό το σύνολο ήταν δραματικά αυξημένος, αγγίζοντας τα 608 λεπτά, αντανakλώντας τον τεράστιο όγκο του συνόλου.
- Η αξιολόγηση στο **σύνολο Brain Tumor** αποκάλυψε μια κρίσιμη συμπεριφορά του πειράματος, καθώς εξέτασε τη μεταφορά γνώσης σε δεδομένα άνευ αρχικών επισημειώσεων (ground truth). Συγκεκριμένα, οι συνθετικές μάσκες που παρήχθησαν από το Vanilla U-Net οδήγησαν σε ισχυρά μοντέλα YOLO με M_mAP50 0.757 (YOLOv11x-seg). Αντίθετα, οι μάσκες του Guided U-Net οδήγησαν σε πλήρη κατάρρευση της απόδοσης, με το M_mAP50 να φτάνει το 0.434. Το γεγονός αυτό καταδεικνύει ότι, ενώ το απλό U-Net διαθέτει ισχυρή ικανότητα γενίκευσης σε νέα MRI δεδομένα, η προσέγγιση καθοδήγησης από οριακά πλαίσια (Guided) είναι εξαιρετικά ευάλωτη στη μετατόπιση πεδίου.

Η άμεση σύγκριση των δύο αρχιτεκτονικών αναδεικνύει ένα ενδιαφέρον αντιστάθμισμα. Στο ευκολότερο σύνολο (BUSI), το YOLOv26x-seg επέδειξε ελαφρώς ανώτερη ικανότητα γενίκευσης, ξεπερνώντας το YOLOv11x-seg (M_mAP50: 0.887 έναντι 0.877 με δεδομένα Guided U-Net). Ωστόσο, στο πιο απαιτητικό σύνολο (BraTS), το YOLOv11x-seg αποδείχθηκε σαφώς πιο ισχυρό, επιτυγχάνοντας M_mAP50 0.617 έναντι 0.585 του YOLOv26x-seg. Συμπερασματικά, το YOLOv11 φαίνεται να διαχειρίζεται καλύτερα τη μεταφορά γνώσης σε πολύπλοκα ιατρικά μοτίβα, ενώ είναι ταυτόχρονα και ταχύτερο στην εκπαίδευση.

4

Συμπεράσματα - Επίλογος

Η παρούσα εργασία είχε ως πρωταρχικό σκοπό την ανάπτυξη ενός πλήρως αυτοματοποιημένου pipeline για την παραγωγή συνθετικών δεδομένων κατάτμησης σε ογκολογικές ιατρικές εικόνες, μειώνοντας την εξάρτηση από τις χρονοβόρες χειροκίνητες επισημειώσεις. Μέσα από την αξιολόγηση 12 διαφορετικών μεθόδων και την επακόλουθη εκπαίδευση μοντέλων YOLO, εξήχθησαν κρίσιμα συμπεράσματα τόσο σε θεωρητικό όσο και σε πρακτικό επίπεδο.

4.1 Σύνοψη και Ερμηνεία Ευρημάτων

4.1.1 Φάση 1

Οι κλασικές μέθοδοι υπολογιστικής όρασης αποδείχθηκαν εξαιρετικά ταχείες, ωστόσο η ακρίβειά τους (IoU) ήταν ανεπαρκής, καθώς αδυνατούν να διαχειριστούν τον εγγενή θόρυβο των ιατρικών εικόνων (όπως το speckle noise στους υπερήχους του BUSI) [5], [16]. Αντίθετα, τα επιβλεπόμενα δίκτυα (*Vanilla U-Net* [12] και *Guided U-Net* [13]) λειτούργησαν ως "oracle baselines", επιτυγχάνοντας τις υψηλότερες τιμές επικάλυψης (άνω του 0.85 IoU), απαιτώντας όμως σημαντικό χρόνο προ-εκπαίδευσης. Το Μοντέλο Βάσης (SAM [1]) αναδείχθηκε ως η ιδανική "χρυσή τομή", προσφέροντας ισχυρή zero-shot ικανότητα και υψηλό IoU αποκλειστικά με καθοδήγηση από bounding boxes, αν και ο χρόνος εξαγωγής συμπερασμάτων (inference) σε GPU ήταν αυξημένος.

4.1.2 Φάση 1D

Η μελέτη της δυναμικής εκπαίδευσης των δικτύων κατάτμησης (*U-Net* και *Guided U-Net*) αποκαλύπτει ότι η σταθερή και ομαλή σύγκλιση της συνάρτησης απώλειας μεταφράζεται άμεσα σε υψηλή γενικευσιμότητα, εδραιώνοντας τον ρόλο τους ως το ανώτατο θεωρητικό όριο ακρίβειας του pipeline. Η εμφάνιση ήπιων φαινομένων υπερεκπαίδευσης στο σύνολο BraTS 2020 [2] μετά τη 17η εποχή υποδηλώνει έναν εγγενή περιορισμό: η υψηλή χωρική πολυπλοκότητα και η χαμηλή αντίθεση των δομών της μαγνητικής τομογραφίας (MRI) απαιτούν αυστηρότερο έλεγχο της χωρητικότητας του μοντέλου σε σχέση με τους υπερήχους [17]. Συμπερασματικά, η Φάση 1D αποδεικνύει ότι τα "oracle baselines", παρά το υπολογιστικό τους κόστος σε GPU, είναι απαραίτητα για να οριστεί η βέλτιστη κατανομή των pixel, χρησιμεύοντας ως ο απόλυτος γνώμονας για την αξιολόγηση όλων των υπόλοιπων zero-shot ή κλασικών μεθόδων.

4.1.3 Φάση 2

Η ενσωμάτωση των συνθετικών μασκών στην εκπαίδευση των downstream ανιχνευτών YOLO αναδεικνύει μια θεμελιώδη σχέση μεταξύ της αρχιτεκτονικής του μοντέλου και της πολυπλοκότητας του κλινικού πεδίου [18]. Η παρατηρούμενη συμπεριφορά, όπου το YOLOv26 [14] υπερέχει στο απλούστερο περιβάλλον του BUSI (υπέρηχοι) αλλά υστερεί έναντι του YOLOv11 [15] στο απαιτητικό περιβάλλον του BraTS (MRI), υποδηλώνει ότι οι αρχιτεκτονικές δομές του δεύτερου διαθέτουν μεγαλύτερη ικανότητα διαχείρισης σύνθετων, πολυπαραμετρικών χωρικών μοτίβων.

Το γεγονός ότι επιτεύχθηκαν εξαιρετικά υψηλά mAP στο σύνολο BUSI (έως 0.888) αποδεικνύει συμπερασματικά ότι οι ψευδο-επισημειώσεις που προκύπτουν από τα φθηνά bounding boxes είναι πρακτικά ισοδύναμες με τις πανάκριβες χειροκίνητες επισημειώσεις, καθιστώντας τις απόλυτα έγκυρες για την εκπαίδευση real-time κλινικών εργαλείων, όταν η εφαρμογή είναι επαρκώς απλοϊκή (όπως στο Breast Ultrasound Dataset).

Τέλος, τα αποτελέσματα στο σύνολο Brain Tumor απέδειξαν έμπρακτα ότι το *Vanilla U-Net* αποτελεί μια πολύ πιο αξιόπιστη λύση (0.757 mAP) για cross-domain μεταφορά γνώσης σε σχέση με το *Guided U-Net* (0.434 mAP). Αποδεικνύεται συνεπώς ότι όταν εφαρμόζουμε το pipeline σε εντελώς νέα κλινικά δεδομένα, η απουσία αυστηρής χωρικής καθοδήγησης (vanilla approach) επιτρέπει στο νευρωνικό δίκτυο να αναγνωρίζει οπτικά μοτίβα ανεξάρτητα από τη μέθοδο παραγωγής των οριακών πλαισίων. Αντίθετα, η "τυφλή" εξάρτηση του *Guided U-Net* από τις χωρικές συντεταγμένες των bounding boxes οδηγεί σε υπερεκπαίδευση στη σχέση κουτιού-μάσκας του αρχικού συνόλου, καθιστώντας το εξαιρετικά εύθραυστο σε οποιαδήποτε μετατόπιση πεδίου.

4.2 Θεωρητική και Πρακτική Σημασία

Από **θεωρητική σκοπιά**, η εργασία αυτή προσφέρει μια ολοκληρωμένη απάντηση και εμπειρική τεκμηρίωση στους προβληματισμούς της διεθνούς ακαδημαϊκής κοινότητας. Καταρρίπτει την παραδοσιακή παραδοχή ότι οι απλοί, handcrafted αλγόριθμοι (όπως ο συνδυασμός Otsu+Watershed) επαρκούν για τη σύγχρονη ιατρική απεικόνιση. Παράλληλα, εισάγει ένα αυστηρό πλαίσιο σύγκρισης που οριοθετεί με ακρίβεια πού υπερέχουν τα Foundation Models (SAM) και πού τα εξειδικευμένα δίκτυα (Guided U-Net), εμπλουτίζοντας τη βιβλιογραφία γύρω από το box-supervised instance segmentation.

Σε **πρακτικό επίπεδο**, η σημασία της μεθοδολογίας είναι καταλυτική για την κλινική ογκολογία. Η χειροκίνητη σχεδίαση πολυγώνων αποτελεί το μεγαλύτερο bottleneck στην ανάπτυξη ιατρικής τεχνητής νοημοσύνης. Η επιτυχής αυτοματοποίηση της μετατροπής μασκών σε πολύγωνα και η απόδειξη ότι αυτά τα συνθετικά δεδομένα μπορούν να εκπαιδεύσουν επαρκώς μοντέλα YOLO, ανοίγει τον δρόμο για τον εκδημοκρατισμό της

ανάπτυξης μοντέλων AI. Νοσοκομεία και ερευνητικά κέντρα που διαθέτουν τεράστιες, ανεκμετάλλευτες βάσεις δεδομένων με απλά bounding boxes μπορούν πλέον να τις αναβαθμίσουν αυτόματα σε datasets υψηλής αξίας για instance segmentation, μειώνοντας το κόστος και τον χρόνο εργασίας των εξειδικευμένων ιατρών στο ελάχιστο.

4.3 Περιορισμοί και Μελλοντική Έρευνα

Παρά τα εξαιρετικά συμπεράσματα, η παρούσα μελέτη εντοπίζει συγκεκριμένους περιορισμούς που θέτουν τις βάσεις για τη μελλοντική ερευνητική δραστηριότητα:

- Όπως αποδείχθηκε πειραματικά από την κατακόρυφη πτώση της απόδοσης του Guided U-Net (0.434 mAP) στο σύνολο Brain Tumor, η μετατόπιση πεδίου λόγω διαφορετικών κλινικών πρωτοκόλλων ή μηχανημάτων MRI παραμένει ο σημαντικότερος περιορισμός. Η ανάπτυξη μεθοδολογιών μη-επιβλεπόμενης προσαρμογής πεδίου αποτελεί άμεση προτεραιότητα [19].
- Η απομόνωση αμιγώς δισδιάστατων αξονικών τομών (2D axial slices) από τις μαγνητικές τομογραφίες του BraTS στερεί από τα μοντέλα την πολύτιμη 3D στερεοσκοπική πληροφορία και τη συνέχεια των ογκολογικών δομών. Η επέκταση του pipeline σε 2.5D (χρήση γειτονικών slices) ή αμιγώς 3D αρχιτεκτονικές αποτελεί αναγκαίο επόμενο βήμα [20].
- Αν και το Segment Anything Model (SAM) επέδειξε εντυπωσιακή zero-shot προσαρμοστικότητα, σχεδιάστηκε για γενικές εικόνες. Η μελλοντική έρευνα οφείλει να ενσωματώσει και να αξιολογήσει ιατρικά ρυθμισμένα μοντέλα βάσης, όπως το SAM-Med2D [21]. Αναμένεται ότι η χρήση τέτοιων εξειδικευμένων ιατρικών μοντέλων θα κλείσει πλήρως το χάσμα ακρίβειας με τα πλήρως επιβλεπόμενα δίκτυα, προσφέροντας βέλτιστα συνθετικά datasets χωρίς καμία ανάγκη τοπικής προ-εκπαίδευσης.

5

Βιβλιογραφία

- [1] A. Kirillov *et al.*, "Segment Anything," *arXiv preprint arXiv:2304.02643*, 2023.
- [2] B. H. Menze *et al.*, "The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)," *IEEE Transactions on Medical Imaging*, vol. 34, no. 10, pp. 1993–2024, 2015.
- [3] S. Bakas *et al.*, "Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features," *Scientific Data*, vol. 4, p. 170117, 2017.
- [4] S. Bakas *et al.*, "Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation, Progression Assessment, and Overall Survival Prediction in the BRATS Challenge," *arXiv preprint arXiv:1811.02629*, 2019.
- [5] W. Al-Dhabyani, M. Gomaa, H. Khaled, and A. Fahmy, "Dataset of breast ultrasound images," *Data in Brief*, vol. 28, p. 104863, 2020.
- [6] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.
- [7] P.-S. Liao, T.-S. Chen, and P.-C. Chung, "A fast algorithm for multilevel thresholding," *Journal of Information Science and Engineering*, vol. 17, no. 5, pp. 713–727, 2001.
- [8] S. Beucher, "Watershed, Hierarchical Segmentation and Waterfall Algorithm," in *Mathematical Morphology and Its Applications to Image Processing*, Springer, 1994, pp. 69–76.
- [9] L. Grady, "Random walks for image segmentation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 28, no. 11, pp. 1768–1783, 2006.
- [10] T. F. Chan and L. A. Vese, "Active contours without edges," *IEEE Transactions on Image Processing*, vol. 10, no. 2, pp. 266–277, 2001.
- [11] P. Marquez-Neila, L. Baumela, and L. Alvarez, "A morphological approach to curvature-based evolution of curves and surfaces," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 36, no. 1, pp. 2–17, 2014.
- [12] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.

- [13] P. Bilic and J. Egger, "Transforming Semantic Segmentation into Instance Segmentation with a Guided U-Net," in *IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, 2023, doi: 10.1109/SMC53992.2023.10324276.
- [14] G. Jocher, J. Qiu, and A. Chaurasia, "Ultralytics YOLO," GitHub repository, 2023.
[Online]. Available: <https://github.com/ultralytics/ultralytics>
- [15] M. T. P. Nguyen, T. N. Le, and M. K. P. Tran, "Leukemia Detection Based on YOLOv11 with Global and Local Contexts Interaction," in *Computational Collective Intelligence*, Springer, 2026.
- [16] J. A. Noble and D. Boukerroui, "Ultrasound image segmentation: a survey," *IEEE Transactions on Medical Imaging*, vol. 25, no. 8, pp. 987–1010, 2006.
- [17] N. Tajbakhsh *et al.*, "Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation," *Medical Image Analysis*, vol. 63, p. 101693, 2020.
- [18] J. Terven, D. Córdova-Esparza, and J. A. Romero-González, "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, 2023.
- [19] S. Guan and M. Liu, "Domain Adaptation for Medical Image Analysis: A Survey," *IEEE Transactions on Biomedical Engineering*, vol. 69, no. 3, pp. 1173–1185, 2022.
- [20] Özgün Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger, "3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2016, pp. 424–432.
- [21] J. Cheng *et al.*, "SAM-Med2D," *arXiv preprint arXiv:2308.16184*, 2023.
- [22] Ultralytics, "Brain Tumor Detection Dataset," Ultralytics Datasets, 2023.